UNIVERSITAS TIDAR

FAKULTAS TEKNIK

PROGRAM STUDI TEKNOLOGI INFORMASI

UJIAN TENGAH SEMESTER (UTS)

PRAKTIKUM BIG DATA — UJIAN LIVE CODING

Mata Kuliah	:	Praktikum Big Data
Program Studi	:	Teknologi Informasi
Materi Ujian	:	Pertemuan 1 s.d. 7
Bentuk Ujian	:	Live Coding (langsung di kelas)
Alokasi Waktu	:	120 menit
Sifat Ujian	:	Closed book — dilarang membuka catatan maupun internet

PETUNJUK UMUM UJIAN

1. Pembagian Paket Soal

Ujian ini terdiri dari DUA paket soal. Kerjakan paket sesuai NPM anda:

- **Mahasiswa dengan NPM berakhiran ANGKA GANJIL (1, 3, 5, 7, 9) → kerjakan PAKET A (halaman 2)**
- **Mahasiswa dengan NPM berakhiran ANGKA GENAP (0, 2, 4, 6, 8) → kerjakan PAKET B (halaman 5)**

2. Lingkungan Kerja (Environment)

Catatan: *Gunakan environment yang SUDAH AKTIF dan telah anda pakai sejak Pertemuan 1-7*

3. Aturan Ujian

a. Ujian bersifat CLOSED BOOK. Dilarang membuka catatan, modul praktikum, slide perkuliahan, maupun mengakses internet dalam bentuk apa pun (termasuk mesin pencari, dokumentasi resmi, forum, maupun AI assistant).

b. Dilarang bekerja sama atau berkomunikasi dengan peserta ujian lain dalam bentuk apa pun selama ujian berlangsung.

c. Kerjakan seluruh soal pada SATU notebook Jupyter baru.

d. Setiap sel kode WAJIB dijalankan (Run) sehingga output-nya terlihat — jawaban tanpa output yang berhasil dijalankan tidak akan dinilai penuh, meskipun sintaksnya benar.

e. Kode yang menghasilkan error dapat tetap memperoleh nilai sebagian apabila logika/pendekatan yang dituliskan sudah menunjukkan pemahaman yang tepat — jangan biarkan sel kosong jika anda memiliki gagasan pendekatan penyelesaiannya, meskipun belum yakin sepenuhnya benar.

f. Jalankan Sub-bab 'Persiapan Data' pada paket soal anda TERLEBIH DAHULU sebelum mengerjakan Soal 1-6 — bagian ini WAJIB dijalankan apa adanya, jangan diubah.

4. Pengumpulan

Simpan notebook dengan format nama: **`UTS_BigData_[NPM]_[Nama Lengkap].ipynb`**. Kumpulkan melalui gform yang diberikan oleh asisten praktikum sebelum waktu ujian berakhir. Pastikan seluruh sel telah dijalankan (Run All) sebelum menyimpan dan mengumpulkan.

PAKET A

Untuk Mahasiswa dengan NPM Berakhiran Angka Ganjil

Studi Kasus: PT Roda Cepat Rental

PT Roda Cepat Rental mengoperasikan tiga cabang (Magelang, Semarang, dan Yogyakarta) yang menyewakan berbagai jenis kendaraan (motor, mobil, city car). Setiap cabang memiliki beberapa staf administrasi yang bertugas memproses transaksi penyewaan, mulai dari verifikasi dokumen hingga serah-terima kendaraan. Manajemen operasional ingin mengevaluasi kecepatan layanan staf — standar internal perusahaan menetapkan bahwa satu proses transaksi dikategorikan 'Sesuai Target' apabila durasi prosesnya tidak lebih dari 20 menit.

Data transaksi penyewaan selama ini dicatat oleh sistem kasir masing-masing cabang, sehingga kualitas datanya belum tentu bersih — sebagaimana lazim terjadi pada data dunia nyata. Sebagai data engineer yang baru bergabung, anda ditugaskan membangun alur analisis dari data mentah hingga laporan siap pakai, menggunakan seluruh infrastruktur Big Data yang telah dipelajari sepanjang semester.

Persiapan Data (Jalankan Terlebih Dahulu)

Buka notebook baru, lalu jalankan kode berikut PERSIS seperti tertulis (jangan diubah) untuk menghasilkan dua sumber data yang akan anda gunakan sepanjang ujian ini.

```
import random
import pandas as pd
import json

random.seed(704)
n = 400
lokasi_list = ["Cabang Magelang", "Cabang Semarang", "Cabang Yogyakarta"]
kategori_dirty = ["motor","Motor","MOTOR","mobil","Mobil",
                  "city car","City Car"]

staf_ids = [f"ST{i:03d}" for i in range(1, 19)]
lokasi_per_staf = {sid: random.choice(lokasi_list) for sid in staf_ids}

rows = []
for i in range(n):
    staf_id = random.choice(staf_ids)
    rows.append({
        "sewa_id": f"SWA-{1000+i}",
        "staf_id": staf_id,
        "cabang": lokasi_per_staf[staf_id],
        "jenis_kendaraan": random.choice(kategori_dirty),
        "durasi_proses_menit": random.randint(3, 40),
        "biaya_sewa": random.choice(
            [50000,100000,150000,200000,300000]),
        "status_sewa": random.choice(
            ["Selesai","Selesai","Selesai","Batal"]),
    })

rows += [rows[6], rows[25], rows[95]]
for idx in [8, 45, 150, 190]:
    rows[idx] = dict(rows[idx])
    rows[idx]["durasi_proses_menit"] = None
for idx in [12, 100]:
    rows[idx] = dict(rows[idx])
    rows[idx]["biaya_sewa"] = None
for idx in [230, 280]:
    rows[idx] = dict(rows[idx])
    rows[idx]["durasi_proses_menit"] = -random.randint(1,10)

pd.DataFrame(rows).to_csv("penyewaan.csv", index=False)
```

```
staf_master = [
    {"staf_id": sid, "nama_staf": f"Staf-{sid}",
     "cabang": lokasi_per_staf[sid],
     "rating_staf": round(random.uniform(3.0,5.0),1)}
    for sid in staf_ids
]
with open("staf.json", "w") as f:
    for s in staf_master:
        f.write(json.dumps(s) + "\n")

print("Data berhasil dibuat: penyewaan.csv dan staf.json")
```

SOAL 1. Ekstraksi Data melalui HDFS (Bobot: 15%)

a. Unggah berkas penyewaan.csv ke HDFS pada direktori /user/[username]/uts/raw/.

b. Baca penyewaan.csv dari HDFS (bukan dari disk lokal) menjadi Spark DataFrame.

c. Baca staf.json menjadi Spark DataFrame.

d. Tampilkan Print Schema nya dan jumlah baris untuk KEDUA DataFrame.

SOAL 2. Eksplorasi dan Pembersihan Data (Bobot: 20%)

Data penyewaan.csv mengandung BEBERAPA masalah kualitas data yang lazim ditemukan pada data dunia nyata. Lakukan eksplorasi untuk menemukan seluruh masalah tersebut, lalu tangani masing-masing.

a. Identifikasi dan tampilkan bukti dari MINIMAL TIGA jenis masalah kualitas data yang berbeda pada penyewaan.csv.

b. Tangani seluruh masalah yang ditemukan pada poin (a). Untuk SETIAP penanganan, tuliskan satu kalimat singkat (markdown cell atau komentar kode) yang menjelaskan alasan pendekatan yang dipilih.

c. Tampilkan jumlah baris data SEBELUM dan SESUDAH proses pembersihan sebagai bukti.

SOAL 3. Transformasi Data dan Penggabungan (Bobot: 20%)

a. Gabungkan data penyewaan yang telah bersih dengan data master staf, menggunakan kunci penggabungan yang tepat.

b. Tambahkan kolom baru kategori_layanan bernilai ‘Sesuai Target’ jika durasi_proses_menit ≤ 20, atau ‘Melebihi Target’ jika sebaliknya.

c. Tambahkan kolom baru biaya_per_menit_proses, dihitung dari biaya_sewa dibagi durasi_proses_menit.

d. Tampilkan 10 baris hasil akhir yang menunjukkan kolom-kolom baru tersebut.

SOAL 4. Analisis dengan Window Function (Bobot: 20%)

a. Untuk SETIAP cabang, tentukan TOP-3 staf dengan jumlah penyewaan berkategori ‘Sesuai Target’ TERBANYAK. Tampilkan cabang, nama_staf, dan jumlahnya.

b. Untuk SETIAP cabang, tentukan SATU staf dengan rating TERTINGGI (catatan: gunakan metode pengurutan berbeda dari poin a).

SOAL 5. Analisis dengan Spark SQL (Bobot: 15%)

Menggunakan Spark SQL murni (spark.sql(), BUKAN DataFrame API), tulis SATU kueri yang menampilkan cabang, total_penyewaan, jumlah_melebihi_target, dan persentase_melebihi_target (dibulatkan 2 desimal) untuk SETIAP cabang, diurutkan dari persentase TERTINGGI. Setelah itu, tulis 1-2 kalimat interpretasi: cabang mana yang paling perlu mendapat perhatian manajemen, dan mengapa?

SOAL 6. Menyimpan Hasil Akhir (ETL Load) **(Bobot: 10%)**

a. Simpan hasil akhir Soal 3 (data gabungan yang telah ditransformasi) ke HDFS dalam format Parquet, dipartisi berdasarkan cabang, pada path /user/[username]/uts/processed/laporan_penyewaan.

b. Verifikasi dengan membaca kembali data tersebut dari HDFS dan menampilkan jumlah barisnya — harus sama dengan jumlah baris hasil Soal 3.

--- AKHIR PAKET A — Periksa kembali seluruh jawaban sebelum mengumpulkan ---

PAKET B

Untuk Mahasiswa dengan NPM Berakhiran Angka Genap

Studi Kasus: PT Techno Service Center

PT Techno Service Center mengoperasikan tiga cabang (Magelang, Semarang, dan Yogyakarta) yang melayani servis perangkat elektronik (laptop, HP, tablet). Setiap cabang memiliki beberapa teknisi yang menangani perbaikan perangkat pelanggan. Manajemen operasional ingin mengevaluasi kecepatan layanan teknisi — standar internal perusahaan menetapkan bahwa satu servis dikategorikan 'Sesuai Target' apabila durasinya tidak lebih dari 60 menit.

Data servis selama ini dicatat oleh sistem tiket internal masing-masing cabang, sehingga kualitas datanya belum tentu bersih — sebagaimana lazim terjadi pada data dunia nyata. Sebagai data engineer yang baru bergabung, anda ditugaskan membangun alur analisis dari data mentah hingga laporan siap pakai, menggunakan seluruh infrastruktur Big Data yang telah dipelajari sepanjang semester.

Persiapan Data (Jalankan Terlebih Dahulu)

Buka notebook baru, lalu jalankan kode berikut PERSIS seperti tertulis (jangan diubah) untuk menghasilkan dua sumber data yang akan anda gunakan sepanjang ujian ini.

```
import random
import pandas as pd
import json

random.seed(707)
n = 400
lokasi_list = ["Cabang Magelang", "Cabang Semarang", "Cabang Yogyakarta"]
kategori_dirty = ["laptop","Laptop","LAPTOP","hp","Hp","HP",
                  "tablet","Tablet"]

teknisi_ids = [f"TK{i:03d}" for i in range(1, 20)]
lokasi_per_teknisi = {kid: random.choice(lokasi_list) for kid in teknisi_ids}

rows = []
for i in range(n):
    teknisi_id = random.choice(teknisi_ids)
    rows.append({
        "servis_id": f"SVS-{1000+i}",
        "teknisi_id": teknisi_id,
        "cabang": lokasi_per_teknisi[teknisi_id],
        "jenis_perangkat": random.choice(kategori_dirty),
        "durasi_servis_menit": random.randint(15, 120),
        "biaya_servis": random.choice(
            [75000,100000,150000,200000,350000]),
        "status_servis": random.choice(
            ["Selesai","Selesai","Selesai","Batal"]),
    })

rows += [rows[5], rows[24], rows[88]]
for idx in [7, 43, 148, 188]:
    rows[idx] = dict(rows[idx])
    rows[idx]["durasi_servis_menit"] = None
for idx in [11, 98]:
    rows[idx] = dict(rows[idx])
    rows[idx]["biaya_servis"] = None
for idx in [228, 278]:
    rows[idx] = dict(rows[idx])
    rows[idx]["durasi_servis_menit"] = -random.randint(1,10)

pd.DataFrame(rows).to_csv("servis.csv", index=False)
```

```
teknisi_master = [
    {"teknisi_id": kid, "nama_teknisi": f"Teknisi-{kid}",
     "cabang": lokasi_per_teknisi[kid],
     "rating_teknisi": round(random.uniform(3.0,5.0),1)}
    for kid in teknisi_ids
]
with open("teknisi.json", "w") as f:
    for k in teknisi_master:
        f.write(json.dumps(k) + "\n")

print("Data berhasil dibuat: servis.csv dan teknisi.json")
```

SOAL 1. Ekstraksi Data melalui HDFS (Bobot: 15%)

a. Unggah berkas servis.csv ke HDFS pada direktori /user/[username]/uts/raw/.

b. Baca servis.csv dari HDFS (bukan dari disk lokal) menjadi Spark DataFrame.

c. Baca teknisi.json menjadi Spark DataFrame.

d. Tampilkan Print Schema nya dan jumlah baris untuk KEDUA DataFrame.

SOAL 2. Eksplorasi dan Pembersihan Data (Bobot: 20%)

Data servis.csv mengandung BEBERAPA masalah kualitas data yang lazim ditemukan pada data dunia nyata. Lakukan eksplorasi untuk menemukan seluruh masalah tersebut, lalu tangani masing-masing.

a. Identifikasi dan tampilkan bukti dari MINIMAL TIGA jenis masalah kualitas data yang berbeda pada servis.csv.

b. Tangani seluruh masalah yang ditemukan pada poin (a). Untuk SETIAP penanganan, tuliskan satu kalimat singkat (markdown cell atau komentar kode) yang menjelaskan alasan pendekatan yang dipilih.

c. Tampilkan jumlah baris data SEBELUM dan SESUDAH proses pembersihan sebagai bukti.

SOAL 3. Transformasi Data dan Penggabungan (Bobot: 20%)

a. Gabungkan data servis yang telah bersih dengan data master teknisi, menggunakan kunci penggabungan yang tepat.

b. Tambahkan kolom baru kategori_layanan bernilai ‘Sesuai Target’ jika durasi_servis_menit ≤ 60, atau ‘Melebihi Target’ jika sebaliknya.

c. Tambahkan kolom baru biaya_per_menit_servis, dihitung dari biaya_servis dibagi durasi_servis_menit.

d. Tampilkan 10 baris hasil akhir yang menunjukkan kolom-kolom baru tersebut.

SOAL 4. Analisis dengan Window Function (Bobot: 20%)

a. Untuk SETIAP cabang, tentukan TOP-3 teknisi dengan jumlah servis berkategori ‘Sesuai Target’ TERBANYAK. Tampilkan cabang, nama_teknisi, dan jumlahnya.

b. Untuk SETIAP cabang, tentukan SATU teknisi dengan rating TERTINGGI (catatan: gunakan metode pengurutan berbeda dari poin a).

SOAL 5. Analisis dengan Spark SQL (Bobot: 15%)

Menggunakan Spark SQL murni (spark.sql(), BUKAN DataFrame API), tulis SATU kueri yang menampilkan cabang, total_servis, jumlah_melebihi_target, dan persentase_melebihi_target (dibulatkan 2 desimal) untuk SETIAP cabang, diurutkan dari persentase TERTINGGI. Setelah itu, tulis 1-2 kalimat interpretasi: cabang mana yang paling perlu mendapat perhatian manajemen, dan mengapa?

SOAL 6. Menyimpan Hasil Akhir (ETL Load) **(Bobot: 10%)**

a. Simpan hasil akhir Soal 3 (data gabungan yang telah ditransformasi) ke HDFS dalam format Parquet, dipartisi berdasarkan cabang, pada path /user/[username]/uts/processed/laporan_servis.

b. Verifikasi dengan membaca kembali data tersebut dari HDFS dan menampilkan jumlah barisnya — harus sama dengan jumlah baris hasil Soal 3.

--- AKHIR PAKET B — Periksa kembali seluruh jawaban sebelum mengumpulkan ---